

Solicitacao de Infraestrutura

AI Token Suppressor - 200+ usuarios, modo ULTRA

Middleware de compressao de prompts antes do envio a LLMs (Claude, GPT, Groq).

Cenario: 200+ colaboradores, estrategia ultra + Ollama em todas as requisicoes.

Junho/2026

Resumo: tres perfis

Perfil	RAM	Disco SSD	vCPU
MINIMO	16 GB	80 GB	4
RECOMENDADO	32 GB	120 GB	8
IDEAL (rodar liso)	48-64 GB	250 GB	16

NAO usar VPS 4 GB para este cenario. Perfil RECOMENDADO e a sugestao para aprovacao em producao. Perfil IDEAL elimina filas longas e lentidao em pico.

Tabela comparativa completa

Criterio	Minimo	Recomendado	Ideal
RAM total	16 GB	32 GB	48-64 GB
Disco SSD	80 GB	120 GB	250 GB
vCPU	4	8	16
GPU	Nao	Opcional	Recomendada
Servidores	1	1 ou 2	2-3
Instancias Ollama	1x 3B	1x 3B	2x 3B ou GPU
Replicas API	1	2	3
Workers Celery	0-1	2	4
Redis cache	512 MB	2 GB	4 GB
Monitoramento	Nao	Sim	Sim+alertas
Ultra ~1700 tokens	30-90 s	15-45 s	3-25 s
200 users ultra	Arriscado	Sim	Folgado
Fila em pico	Longa	Moderada	Curta/rara
Disponibilidade	~95%	~99%	99,5%+
Custo cloud ref.	R\$300-600	R\$800-1500	R\$2k-4k/mes

PERFIL MINIMO - Viavel com limitacoes

Para: piloto ou ate ~50 usuarios ativos no pico; 200 usuarios com fila e espera de 1-3 min por compressao.

Hardware minimo

- RAM: 16 GB (1 servidor)
- vCPU: 4 cores
- Disco: 80 GB SSD
- Rede: 100 Mbps

Software obrigatorio

- Docker 24+, Compose v2, PostgreSQL 15+ pgvector
- Redis 7, Ollama llama3.2:3b (1 instancia), Nginx+SSL
- Containers: redis + api + frontend (sem Grafana)

Comportamento esperado

- Compressao ultra 1700 tokens: 30-90 segundos
- Pico: fila longa; swap possivel
- Disponibilidade ~95%

PERFIL RECOMENDADO - Producao 200+ usuarios

Para: producao oficial. SUGESTAO PARA APROVACAO DO GERENTE.

Hardware recomendado

- RAM: 32 GB
- vCPU: 8 cores
- Disco: 120 GB SSD/NVMe
- Rede: 500 Mbps - 1 Gbps

Arquitetura (preferir 2 servidores)

- Servidor App 16 GB: API x2, Redis, Postgres, Nginx, Celery
- Servidor Inferencia 16 GB: so Ollama (3B + nomic-embed)

Software adicional

- Celery 2 workers, Prometheus + Grafana, backup diario

Comportamento esperado

- Compressao ultra 1700 tokens: 15-45 segundos
- Cache Redis 2 GB: repetidos em menos de 1 s
- Disponibilidade alvo 99%

PERFIL IDEAL - Rodar liso (sem gargalo)

Para: 200+ usuarios sem fila perceptivel, compressao rapida, crescimento ate 500 usuarios, SLA alto.

Hardware ideal

- RAM: 48-64 GB total
- vCPU: 16 cores
- Disco: 250 GB NVMe
- GPU opcional: 16 GB VRAM (ultra em 3-8 s)
- Rede: 1 Gbps

Arquitetura ideal

- API: 3 replicas com load balancer
- Ollama: 2 instancias 3B OU 1 GPU com modelo 7B
- Redis 4 GB, Postgres 8 GB RAM, Celery 4 workers
- Monitoramento + alertas (Slack/email)
- Backup horario Postgres, ambiente homolog 8 GB

Comportamento - rodar liso

- Ultra 1700 tokens: 3-15 s (GPU) ou 10-25 s (2x Ollama CPU)
- Pico 30 req: p95 menor que 30 s
- Cache hit: menos de 500 ms
- Swap: 0% em operacao normal
- Disponibilidade alvo 99,5%+

Stack tecnica (todos os perfis)

Componente	Funcao
Docker 24+ / Compose v2	Orquestracao
PostgreSQL 15+ pgvector	Dados e busca vetorial
Redis 7	Cache + fila Celery
Ollama	Compressao ultra local
Nginx + SSL	HTTPS
Chaves LLM (Groq, OpenAI...)	Apos compressao

Armazenamento (ano 1)

Item	Min Rec Ideal
SO + Docker	15 20 25 GB
Modelos Ollama	3 5 8 GB
PostgreSQL	5 15 40 GB
Redis, logs, backup	15 40 80 GB
TOTAL disco	80 120 250 GB

Texto para solicitacao formal

Solicito provisionamento do AI Token Suppressor para mais de 200 usuarios em modo ultra (maxima economia de tokens com Ollama).

Opcoes apresentadas:

- 1) MINIMO - 16 GB RAM, 80 GB SSD, 4 vCPU - viavel com filas.
- 2) RECOMENDADO - 32 GB RAM, 120 GB SSD, 8 vCPU - producao estavel. SUGIRO ESTA OPCAO.
- 3) IDEAL (rodar liso) - 48-64 GB RAM, 250 GB SSD, 16 vCPU, GPU opcional - sem gargalo e pronto para crescimento.

O ambiente atual de 4 GB nao atende este cenario.